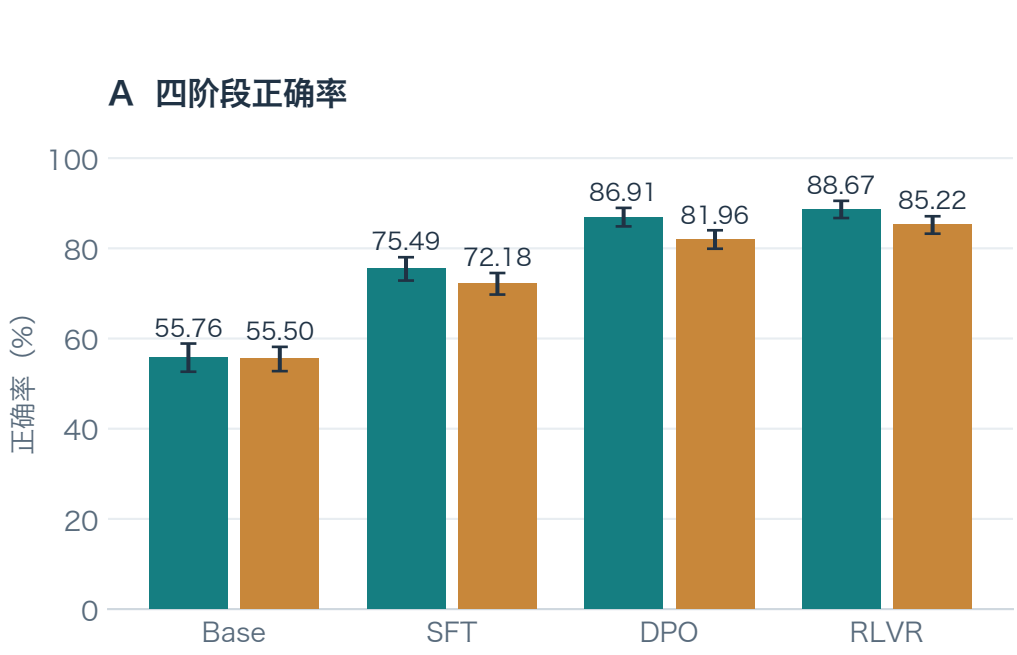
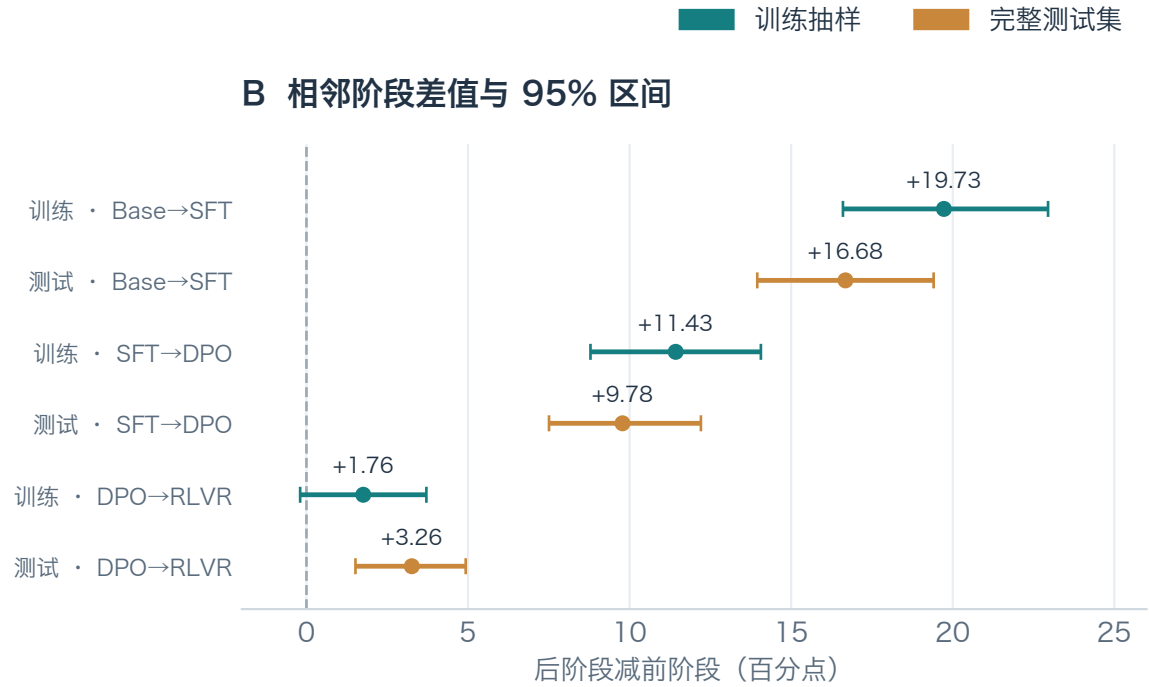
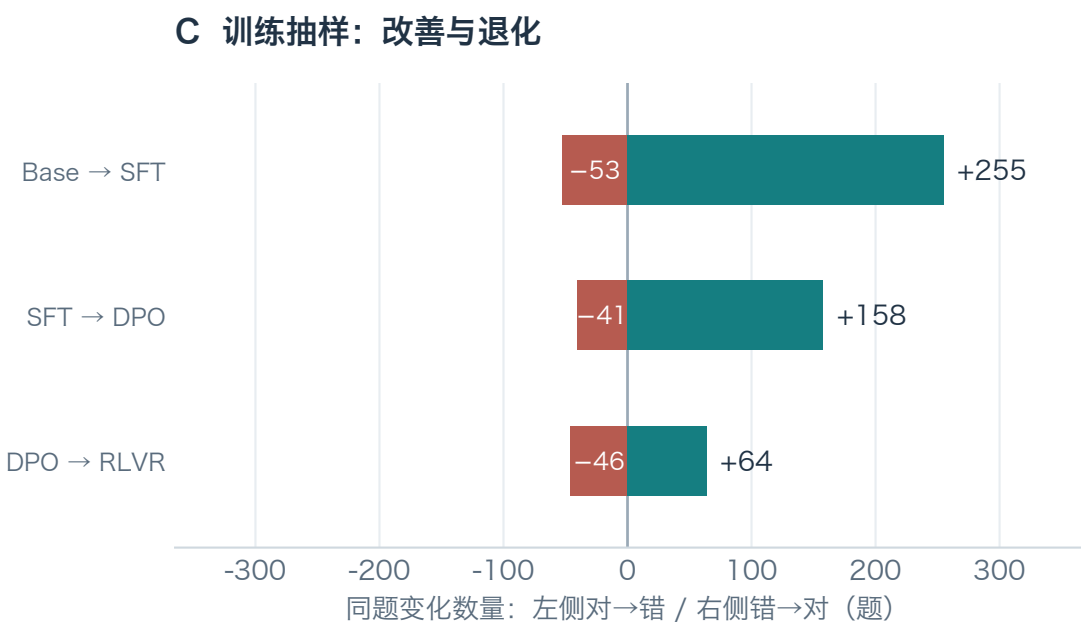
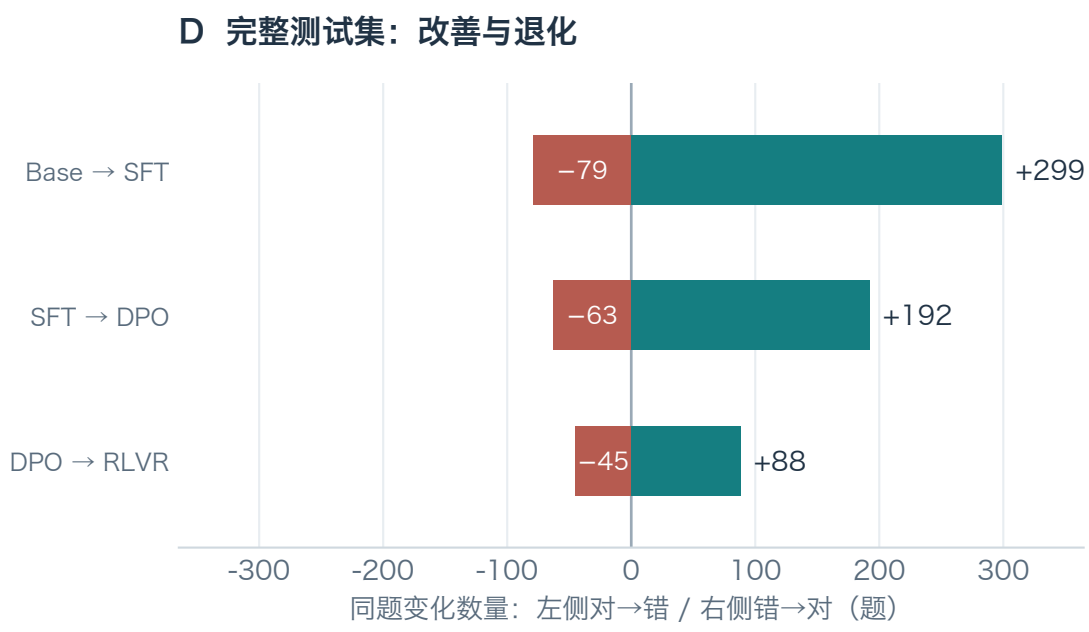
GSM8K | CoT 四阶段主要结果

固定训练抽样 1,024 题 / 完整测试集 1,319 题 · 每种协议 9,372 次正式解答 · 95% bootstrap 区间









B 图零线表示无差值；区间来自按题配对 bootstrap 10,000 次，不包含训练或重跑随机性。

Base → SFT 同时改变权重与调用模板。C/D 展示变化题数，未变化题目仍计入正确率分母。