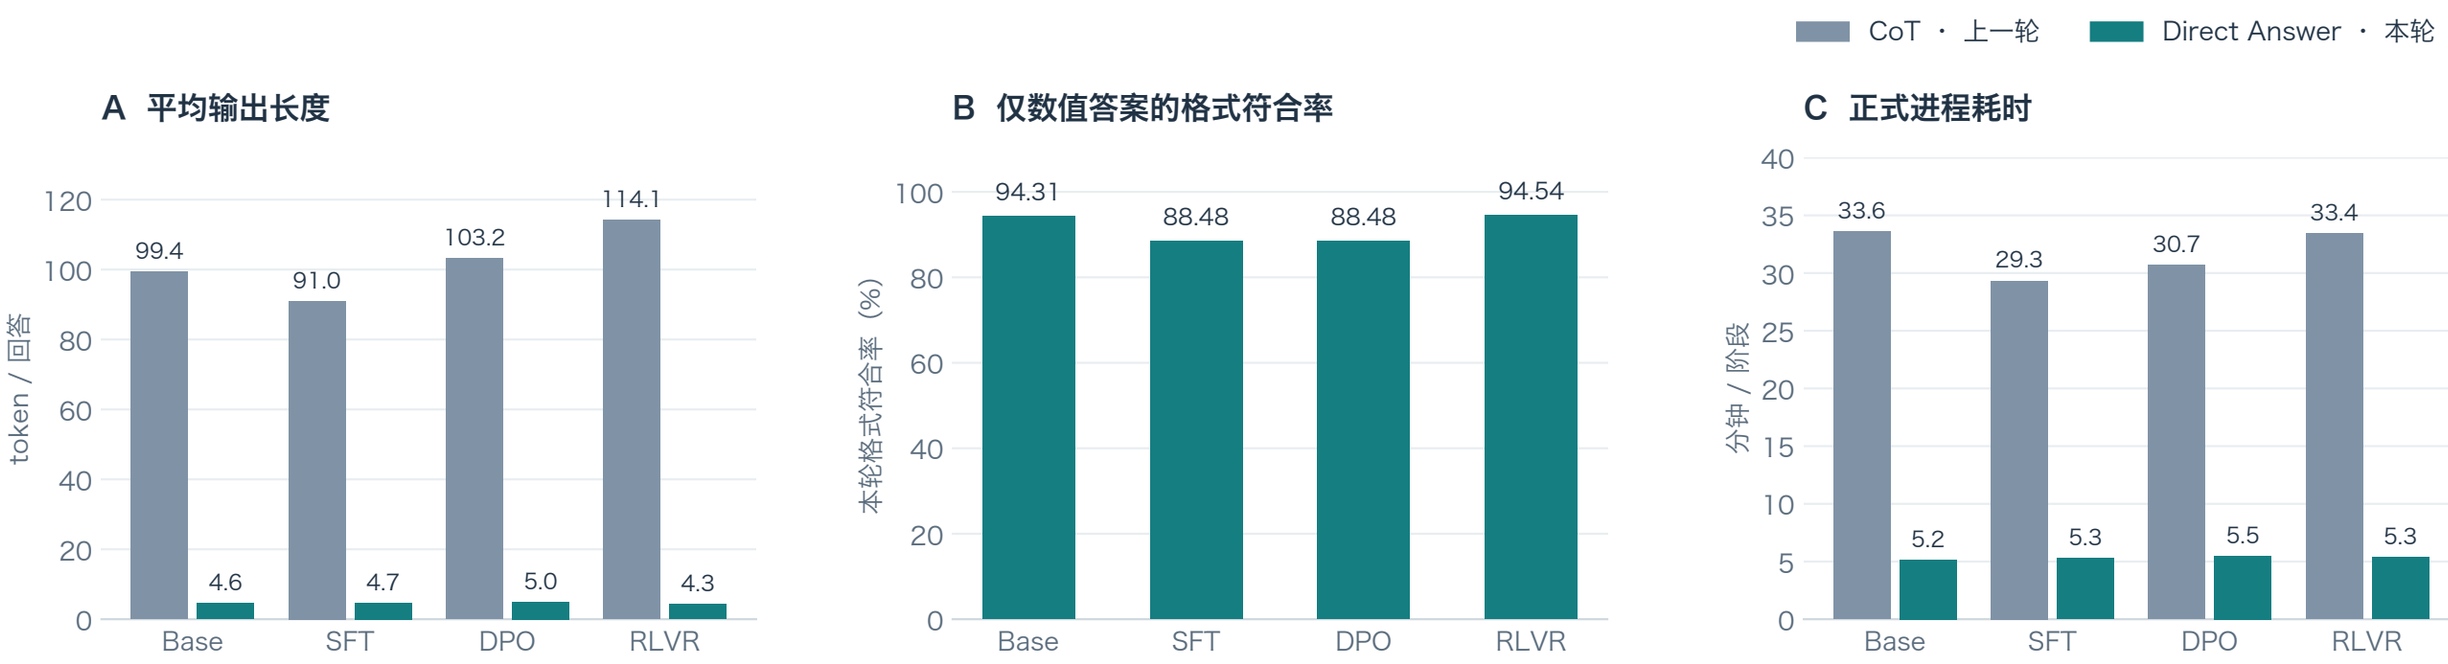
输出诊断 | 答案更短、格式符合率高，正确率仍低

A/B：完整测试集 1,319 题 · C：各阶段训练与测试合计的正式进程耗时（含模型加载）



格式符合率与答案正确率分别计量；格式违规不改变主评分。训练抽样的完整诊断仍见表格。

耗时受缓存、系统负载等影响，不能完全归因于提示变化。