提示选优 | P3 在开发集上得分最高

仅用 dev128（128 句）选优 · 四模型平均严格 Task 1 UPOS · 选定 P3 后冻结提示

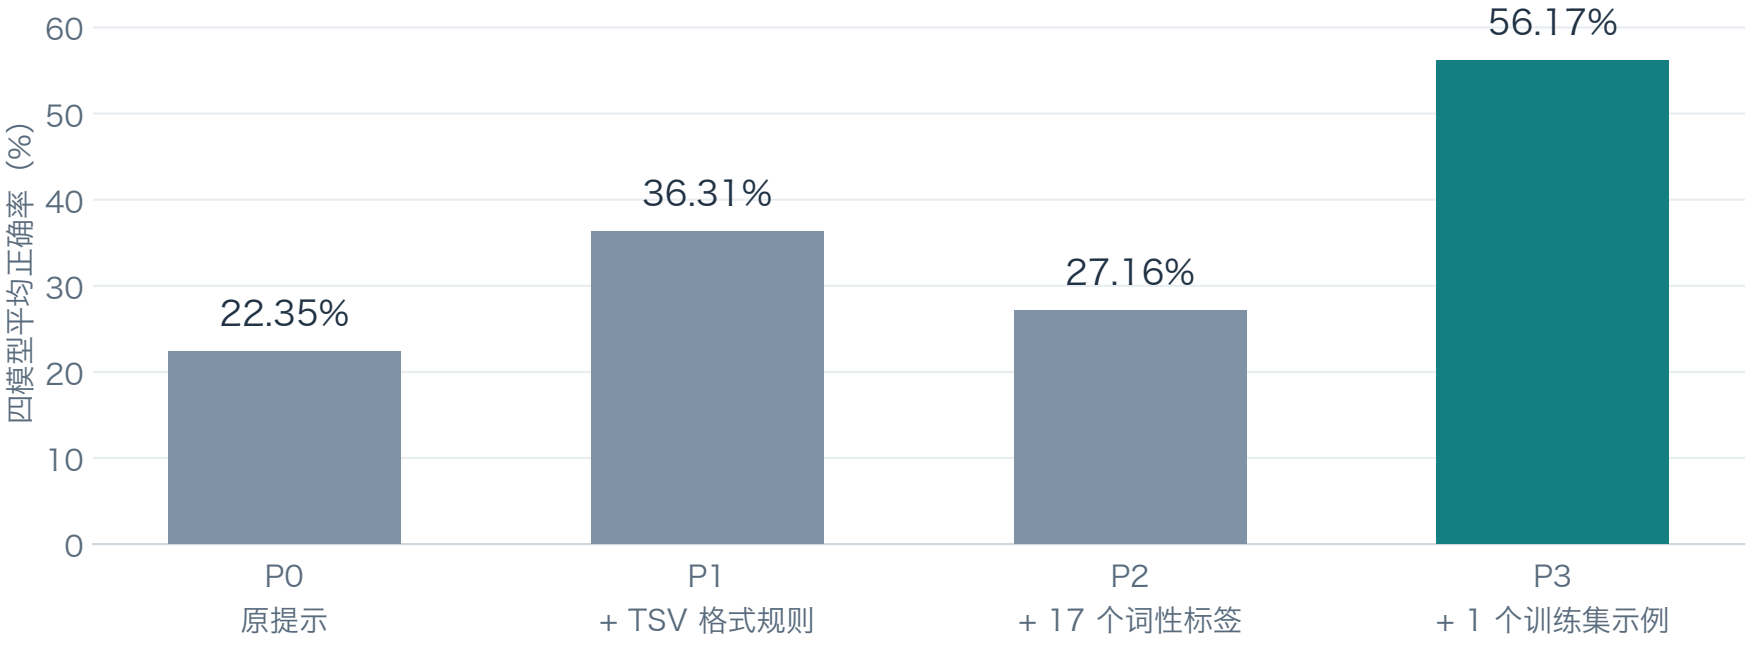

P1/P2 未进行全量测试；P3 收益来自整个提示组合，当前实验不能分离规则、标签和示例的贡献。